


Pipeline 3: Regionales Data Warehouse zur Data-Science-Sandbox

 wiederholte Batchverarbeitung



Erläuterung der Verarbeitungsschritte

1		Abgeschlossene Schadens- und Betrugsfälle aus dem Data Warehouse extrahieren
2		Nur Fälle mit vorliegendem Prüfergebnis auswählen
3		Nicht benötigte personenbezogene Attribute entfernen
4		Kundenzuordnung geschützt außerhalb der Sandbox speichern
5		Fehlende und widersprüchliche Werte behandeln
6		Trainingsrelevante Kennzahlen und Merkmale erzeugen
7	 	Zielvariable trennen und Daten in Trainings-, Validierungs- und Testdaten aufteilen
8		Undersampling ausschließlich auf den Trainingsdaten anwenden
9		Oversampling anschließend nur auf den Trainingsdaten anwenden